

Филиал Московского Государственного Университета
имени М.В. Ломоносова в городе Ташкенте
Факультет прикладной математики и информатики
Кафедра прикладной математики и информатики

Бутузов Игорь Владимирович

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

**НА ТЕМУ: «ПОИСК МАТЕМАТИЧЕСКИХ УТВЕРЖДЕНИЙ В БАЗЕ ДАННЫХ»
ПО НАПРАВЛЕНИЮ 01.04.02 «ПРИКЛАДНАЯ МАТЕМАТИКА И
ИНФОРМАТИКА»**

ВКР рассмотрена и рекомендована к защите
зав. кафедрой «ПМиИ» д.ф.-м.н., профессор _____ Кудрявцев В.Б.

Научный руководитель
к.ф.-м.н. _____ Калачев Г.В.

«_____» _____ 2020 год

Ташкент 2020

Аннотация

Данная работа посвящена разработке программы, способной найти само утверждение или похожее на него в базе данных с математическими теоремами. Такая программа сможет по запросам пользователя ранжировать теоремы таким образом, чтобы теоремы, максимально подходящие под запрос, получали более высокий приоритет при выдаче результата.

В первой части работы приводятся результаты ранжирования теорем из базы с математическими теоремами при использовании 6 алгоритмов. Данная база утверждений состоит из 111 утверждений, количество типов теорем равно 50.

Вторая глава работы посвящена обзору алгоритмов, которые используются для вычисления схожести между текстовыми утверждениями. Также в этой главе описываются методы выявления схожести математических формул, без учета текста на естественном языке.

В третьей главе работы описана работа, реализованной программы. Рассматриваются этапы её работы, описываются алгоритмы работы основных модулей.

Ключевые слова: синтаксический анализ, теорема, функция ранжирования, математическая формула

Abstract

This paper is devoted to the development of a program capable of finding the statement itself or similar to it in a database with mathematical theorems. Such a program will be able to rank the theorems at the user's request so that the theorems that are most suitable for the query receive a higher priority when issuing the result.

The first part of the paper presents the results of ranking theorems from a base with mathematical theorems using 6 algorithms. This statement base consists of 111 statements, the number of types of theorems is 50.

The second chapter of the paper is devoted to a review of algorithms that are used to calculate the similarity between textual statements. Also in this chapter, methods for identifying the similarity of mathematical formulas, without regard to natural language text, are highlighted.

The third chapter of the work describes the work of the implemented program. The stages of its work are considered, the algorithms of the main modules are described.

Keywords: syntax analysis, theorem, ranking function

Содержание

Введение	3
Постановка задачи	4
1 Полученные результаты	6
2 Обзор существующих алгоритмов	9
2.1 Методы выявления схожести математических формул, без учета текста на естественном языке	9
2.2 Описание используемых алгоритмов в программе	10
2.2.1 Алгоритм поиска по ключевым словам	10
2.2.2 Алгоритм Левенштейна	11
3 Описание системы математического поиска	12
3.1 Описание базы данных с математическими утверждениями	12
3.2 Описание модуля перевода текста, написанного на естественном языке, на язык формул логики предикатов	12
3.3 Описание модуля преобразования математических формул	14
3.4 Модуль функции ранжирования	15
3.5 Описание графического интерфейса программы	15
Заключение	17
Список литературы	18

Введение

В настоящее время доказано и ежегодно доказывается огромное количество доказанных теорем и утверждений. Большая часть из которых находится в открытом доступе в сети Интернет. Однако поиск нужного утверждения в столь огромном массиве данных представляется нетривиальной задачей. В особенности это трудно, если автор использовал свою терминологию, а существенная часть утверждения задаётся сложной формулой, поскольку по формулам поисковые системы не ищут, а ключевые слова можно не знать. Для эффективности системы поиска необходимо использовать семантическую структуру утверждения.

Одну и ту же теорему можно записать несколькими способами. Например, изменив обозначения в используемых формулах на эквивалентные или изменив конструкцию, записанную на естественном языке, на конструкцию с тем же смыслом. По этой причине поиск по ключевым словам в теоремах может не дать желаемого результата. Если рассматривать только поиск по формулам, входящим в состав математического утверждения без учета текста на естественном языке, то такой поиск имеет ряд существенных недостатков:

- Формула может встречаться в довольно большом количестве теорем;
- Формула может быть записана при помощи других обозначений или другой формулой с тем же семантическим значением;
- Формула может быть составной частью другой формулы;

Формализация структуры математического утверждения способна повысить вероятность найти искомое утверждение. Для того, чтобы формализовать текст теорем на естественном языке удобно использовать язык логики предикатов. В процессе осуществления такого перевода возникает ряд трудностей. Например, такой процесс не может быть полностью автоматизирован, так как на результат работы программы может сильно измениться из-за неверно истолкованного слова.

Полученное представление текста теоремы на языке логики предикатов является аналогом формулы и оно может быть представлено в виде абстрактного дерева. Объединив такое дерево с формулами из данного утверждения, предварительно представленными в виде деревьев со схожей структуры, можно получить дерево исходного математического утверждения. К такому представлению формулы удобно применять алгоритмы работы с деревьями.

Результат перевода на язык логики предикатов будет более качественным, если входной текст для такого перевода будет структурирован и в нем будет содержаться вся необходимая для перевода информация [1],[2]. Такое представление текста могут дать синтаксические анализаторы. В данной работе используется синтаксический анализатор Stanza [3], для работы которого используется модель СинТагРус [4],[5]. Для преобразования математических формул в форму дерева, используется РБНФ-грамматика (расширенная форма Бэкуса — Наура [7]) и библиотека для Python 3 TatSu [6], которая позволяет по файлу, содержащему правила построения грамматики, построить дерево формулы.

Постановка задачи

Целью данной работы является создание программы, способной найти само утверждение или похожее на него в базе данных с математическими теоремами.

Реализуемая система по введенному пользователю утверждению проведет ранжирование теорем, содержащихся в базе утверждений. В результате ранжирования теоремы, максимально подходящие под запрос, получают более высокий приоритет при выдаче результата.

Актуальность данной темы заключается в том, что ежегодно доказывается несколько сотен тысяч теорем и других математических утверждений. Поиск нужного утверждения в столь огромном массиве данных представляется нетривиальной задачей.

В отличие от поиска по ключевым словам реализуемая система будет иметь более высокий результат, так как будет опираться не на вхождение определенных слов в запрос, а на смысловое содержание введенной теоремы. Поэтому такая система математического поиска сможет сопоставлять теорему, которую ввел пользователь и теорему из базы данных, даже если они записаны при помощи разных формулировок.

Предполагается, что как заданная теорема, так и теоремы из базы данных записаны на естественном языке (возможно, с использованием математических формул, представленных в формате системы TeX [8]). При этом в программе должно учитываться, что формулировки заданной теоремы и той же теоремы в базе данных могут несколько отличаться.

В процессе работы было решено несколько промежуточных задач:

1. Задача перевода текста, написанного на естественном языке, на язык формул логики предикатов (с помощью синтаксического и семантического анализа), и последующего представления этих формул в виде деревьев;
2. Задача представления в том же виде формул, записанных в формате системы TeX;
3. Задача ранжирования формул базы данных, записанных в виде деревьев, по степени похожести на формулу теоремы-запроса.

Кроме того, для проверки работоспособности программы необходима база теорем, а также некоторое множество теорем, выступающих в качестве запросов к программе.

В качестве входных данных для данной программы используется синтаксический анализ Stanza. Программа реализована на языке Python 3[9],[10]. Результатом работы программы является представление базы математических утверждений, в которых формулировка искомой теоремы или похожей на нее должна появиться среди лучших кандидатов, найденных программой.

Сформулируем основные понятия, используемые в данной работе:

Токен — слово, устойчивое выражение или знак препинания. Токен имеет словоформу, лемму и набор морфологических характеристик.

Синтаксическое дерево зависимостей — способ представления синтаксической структуры предложения. В узлах дерева расположены токены данного предложения [11]. Под словами «родительский» и «дочерний» по отношению к токенам в данной работе следует понимать отношения между соответствующими узлами дерева. Каждому токену (исключение составляет корень синтаксического дерева) поставлено в соответствие положительное число — номер другого токена, который является родителем для данного. Для корня синтаксического дерева это число равно нулю. Между «родительским» и «дочерним» токенами устанавливается синтаксическое отношение, его мы будем называть типом связи. У корня синтаксического дерева родителя нет.

Словоформа — форма слова, полученная из основной части слова с помощью склонения и спряжения.

Лемма — словарная форма слова.

Коэффициент Жаккара [12] - бинарная мера сходства, предложенная Полем Жаккаром в 1901 году. Для множеств A и B вычисляется коэффициент Жаккара по следующей формуле:

$$K = \frac{n(A \cap B)}{n(A \cup B)}, \text{ где } n(C) - \text{ количество элементов в множестве } C$$

Если оба множества состоят из одинаковых элементов, то коэффициент K равен 1. Чем больше различий между множествами, тем значение K ближе к 0.

Расстояние Левенштейна - метрика, измеряющая разность между двумя последовательностями символов. Она определяется как минимальное количество односимвольных операций (а именно вставки, удаления, замены), необходимых для превращения одной последовательности символов в другую.[13]

Косинусное сходство — это мера сходства между двумя векторами, которая используется для измерения косинуса угла между ними. Если даны два вектора признаков, A и B , то косинусное сходство, $\cos(\theta)$, может быть представлено используя скалярное произведение и норму:

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Будем считать, что косинусное сходство принимает значения от 0 до 1 и чем ближе его значение к 1, тем больше сходства между рассматриваемыми объектами.

1 Полученные результаты

В результате данной работы была реализована программа, которая способна найти само утверждение или похожее на него в базе данных с математическими теоремами.

Данная программа может по запросам пользователя ранжировать теоремы таким образом, чтобы теоремы, максимально подходящие под запрос, получали более высокий приоритет при выдаче результата.

Работа программы тестировалась на базе утверждений, состоящей из 111 теорем. Среди данных теорем встречаются разные формулировки одних и тех же теорем. Каждой теореме соответствует свой отдельный класс. Общее количество таких классов для данной базы данных равно 50. Исследовалось качество работы 6 алгоритмов.

Алгоритм 1

1. На вход подается утверждение теоремы или таблица (массив), содержащая порядковый номер токена, его словоформу, лемму, номер родительского токена, тип синтаксической связи и часть речи. Предварительно, все формулы в данном утверждении заменены на обозначение «formula_№», где - порядковый номер в списке формул.

2. При помощи специально написанного словаря группы токенов, образующих устойчивое выражение объединялись в один. По словарю с синонимами токены и группы токенов заменялись на общее обозначение.

3. Дерево синтаксического разбора перестраивалось таким образом, чтобы вершины дерева с обозначениями forall , if , then , \Leftrightarrow , exists стали вершинами максимально возможных по размеру поддеревьев.

4. По дереву синтаксического разбора строится список вложенных списков (массив вложенных массивов), где вершиной списка является родительская вершина.

5. В данный список вложенных списков вместо обозначений «formula_№» подставляется дерево разбора соответствующей формулы.

6. Данный список разбивается на множество вложенных списков.

7. При помощи коэффициента Жаккара множества вложенных списков сравниваются с аналогичными множествами, построенными для каждой теоремы из базы утверждений.

Алгоритм 2. Алгоритм поиска по ключевым словам. На вход подается текстовое утверждение теоремы. Метод основан на частоте встречаемости слов и словосочетаний в базе утверждений.

Алгоритм 3. Модификация алгоритма 1 с учетом использования ключевых слов .

1. Повторяются шаги 1-6 Алгоритма 1.

2. Для всех слов, входящих в состав множества вложенных списков составляется таблица весов. Чем реже встречается какое-либо слово, тем выше у него вес в данной таблице. При помощи данной таблицы вычисляется вес каждого множества вложенных списков. Допустим есть два вектора с весами $x = (x_1, x_2, \dots, x_n)$ и $y = (y_1, y_2, \dots, y_n)$

3. По формуле $J_w(x, y) = \frac{\sum_i \min(x_i, y_i)}{\sum_i \max(x_i, y_i)}$ вычислялось сходство двух множеств.

Алгоритм 4. Схожесть двух текстовых утверждения теорем сравнивалась при помощи расстояния Левенштейна .

Алгоритм 5. Текст двух текстовых утверждений делился на множество слов. Данные множества сравнивались при помощи меры Косинусного сходства .

Алгоритм 6. Текст двух текстовых утверждений делился на множество слов. Данные множества сравнивались при помощи Коэффициента Жаккара

Качество работы алгоритма оценивалось по двум метрикам.

Метрика 1.

Для тестирования каждой теореме присваивался свой уникальный номер. Номера формулировок одних и тех же теорем объединялись в некоторые множества номеров. Допустим, нам известно, что формулировки теоремы Больцано-Коши имеют номера 1,2. Соответственно, множество номеров для данной теоремы $\{1, 2\}$.

1. Для каждой теоремы из файла, содержащего утверждения теорем, строилась своя формула и данная формула заносилась в базу данных. Таким образом, строилась база формул с которой и происходило сравнение заданной формулы.

2. Формула для которой проводилось ранжирование сравнивалась Алгоритмами 1-6 с остальными формулами базы данных. Таким образом, строилась таблица ранжирования для данной формулы.

3. Каждый индекс формулы в таблице ранжирования сравнивался с множеством номеров, содержащих номер заданной теоремы. Если текущего индекса в таблице ранжирования нет в массиве номеров, то накладывался штраф, равный 1. Чем меньше штрафов было получено, тем лучше качества ранжирования.

Опишем алгоритм на примере. Имеется база данных формул в количестве 111 элементов. A_i ($i = 1..111$). Для каждого i известны индексы той же самой теоремы, но в другой формулировке. Предположим, что для теоремы с номером i теоремой с другой формулировкой будет теорема с индексом j ($j \neq i, j = 1..111$). Для данной теоремы множество номеров равно $\{i, j\}$.

Выберем произвольный номер k ($k = 1, \dots, 111$). Сравним разбор теоремы A_k с каждой имеющейся в базе данных формул A_i . Получим таблицу ранжирования с индексами формул p_1, p_2, \dots, p_{111} . Величина текущего штрафа будет храниться в переменной *Penalty*.

$m = 1..111$, $m! = i$:

Если $p_m \neq j$, то $Penalty = Penalty + 1$

Если $p_m == j$, то алгоритм завершит работу.

Итоговое значение для данной теоремы равно:

$$Result_1 = 1 - \frac{Penalty}{size(A)}$$

Метрика 2.

Опишем алгоритм на примере. Пусть имеется база утверждений A , состоящая из 111 теорем. Пусть результат работы функции ранжирования $[X_1, Y_1, X_2, X_3, Y_2, Y_3, X_4, \dots]$. Найдем номера всех теорем X , формулировки которых мы ищем, кроме самой первой. Предположим, что искомые теоремы имеют номера 3,4,7. Если бы алгоритм отработал точно, то номера искоемых теорем были бы равны 2,3,4. Оценка для данного примера равна:

$$Result_2 = 1 - \frac{3 + 4 + 7 - 2 - 3 - 4}{3 \cdot size(A)} \approx 0.985$$

Для тестовой выборки из 111 теорем были получены следующие результаты:

№ алгоритма	Метрика 1	Метрика 2
Алгоритм 1	0.951	0.975
Алгоритм 2	0.949	0.792
Алгоритм 3	0.889	0.945
Алгоритм 4	0.768	0.889
Алгоритм 5	0.847	0.927
Алгоритм 6	0.867	0.938

Таблица 1: Результаты для 111 теорем. Значения Метрика 1 и Метрика 2 получены как средние значения $Result_1$ и $Result_2$ к общему количеству теорем соответственно

2 Обзор существующих алгоритмов

2.1 Методы выявления схожести математических формул, без учета текста на естественном языке

Как отмечалось ранее, поиск по формулам, входящим в состав математического утверждения, без учета текста, записанного на естественном языке имеет ряд существенных недостатков: например, формула может встречаться в нескольких теоремах, она может быть записана при помощи других обозначений, другой формулой с тем же семантическим значением или являться частью другой более длинной теоремы.

Однако методы, используемые при таком поиске, могут быть востребованы, если получится представить математическое утверждение вместе с формулой и текстом на естественном языке в виде некоторой обобщенной формулы.

В работе [14] исследуется структурно-синтаксическое сходство математических выражений. Основное внимание уделяется модификации алгоритма наложения деревьев зависимостей для математических выражений, представленных в MathML. Рассмотрено применение трех алгоритмов.

В данной работе описано применение алгоритма Tree edit distance (Расстояние редактирования дерева) для математических выражений. Данный алгоритм определяет схожесть между двумя деревьями как число операций добавления, удаления и изменения для того, чтобы преобразовать одно дерево в другое.

Также в данной работе рассмотрен алгоритм Subpath set (Множество подпутей). Подпутем называется множество всех путей из корневой вершины к остальным вершинам, включая промежуточные пути. Коэффициент схожести в данном алгоритме определяется как число общих подпутей у рассматриваемых деревьев.

Третьим представленным алгоритмом является модификация Tree overlapping algorithm (Алгоритм наложения деревьев). Данный алгоритм может быть описан следующим образом: при наложении произвольной вершины n_1 дерева T_1 на вершину n_2 дерева T_2 может возникнуть одинаковое продукционное правило наложения деревьев T_1 и T_2 . Под схожестью в данном алгоритме понимается количество таких продукционных правил.

В работе [15] описан подход сравнения двух математических формул, представленных в MathML, при помощи чередования прямого и обратного обходов деревьев. Эксперимент показал, что описанный алгоритм не только определяет сходство математических формул по одинаковой структуре, но и семантическое сходство с высокой точностью.

В работе [16] предлагается использовать язык разметки MathML и ранее описанный алгоритм Subpath set.

2.2 Описание используемых алгоритмов в программе

2.2.1 Алгоритм поиска по ключевым словам

В основе работы поисковых систем лежит поиск по ключевым словам и группам слов. Данные системы показывают хороший результат поиска. Поэтому представляет интерес использовать схожий подход при работе с математическими утверждениями.

Два предложения будут максимально похожи, если у них имеется большее количество общих слов или групп слов с высоким весом.

1. Проводим индексирование базы данных. Для каждого слова из базы утверждений определяем его лемму.

2. Для каждого утверждения R выписываем какое слово встретилось сколько раз. При помощи словаря синонимов, в котором слова разбиты на классы эквивалентности вместо самого слова записывается его класс эквивалентности. Для каждого слова A получим величину $N(R, A)$.

3. Такую же информацию сохранить для словосочетаний из двух слов. Словосочетание AB учитывается, если A и B не предлоги, между словами A и B нет знаков препинания. Если между A и B есть k других слов без учёта предлогов, то словосочетание учитывается с весом $\frac{1}{k}$. Словосочетание BA также добавляется с весом $\frac{1}{2k}$. Для каждой пары слов A, B получим величину $N(R, AB)$.

4. Для каждого слова и словосочетания X суммируем величины $N(R, X)$ по всем утверждениям R из базы данных, получим сумму $S(X)$. Слову или словосочетанию X присваивается вес $W(X) = \frac{1}{S(X)}$.

5. При поиске для данного запроса также вычисляются количество раз, которое встретилось каждое слово и словосочетание (тем же методом). После этого ищется утверждение с наиболее похожими характеристиками.

6. Схожесть A и B вычислим по формуле

$$J_w(A, B) = \frac{\sum_i \min(A_i, B_i)}{\sum_i \max(A_i, B_i)}$$

Элементы формул также считаются словами. Слова из английских букв и числа выделяются, как целые слова, а остальные символы считаются отдельными словами или знаками препинания.

2.2.2 Алгоритм Левенштейна

Расстояние Левенштейна называется метрика, измеряющая разность между двумя последовательностями символов. Она определяется как минимальное количество операций вставки, удаления, замены одного символа, необходимых для превращения одной последовательности символов в другую .

Элементы строк в данном алгоритме нумеруются с первого элемента.

Пусть s_1 и s_2 — две строки длиной M и N соответственно над некоторым алфавитом, то расстояние Левенштейна $d(s_1, s_2)$ можно подсчитать по формуле

$d(s_1, s_2) = D(M, N)$, где

$$D(i, j) = \begin{cases} 0, & i = 0, j = 0 \\ i, & j = 0, i > 0 \\ j, & i = 0, j > 0 \\ \min\{ & \\ \quad D(i, j - 1) + 1, & \\ \quad D(i - 1, j) + 1, & j > 0, i > 0 \\ \quad D(i - 1, j - 1) + m(s_1[i], s_2[j]) & \\ \} & \end{cases},$$

где $m(a, b) = 0$, если $a = b$, $m(a, b) = 1$, если $a \neq b$

$\min\{a, b, c\}$ возвращает наименьший из аргументов.

Здесь шаг по i символизирует удаление (D) из первой строки, по j — вставку (I) в первую строку, а шаг по обоим индексам символизирует замену символа (R) или отсутствие изменений (M).

3 Описание системы математического поиска

3.1 Описание базы данных с математическими утверждениями

Для тестирования работы реализованной программы были выбраны 111 теорем на русском языке из википедии и различных учебных пособий. Теоремы были взяты из математического анализа, функционального анализа и теории рядов.

1. Все теоремы были разделены на классы эквивалентности. Общее количество классов равно 50. В отдельный файл заносится принадлежность теорем к определенному классу эквивалентности

2. Произведено разделение текстовой части утверждения теорем и содержащихся в них математических формул на языке TeX. Формулы добавлялись в отдельный текстовый файл, а в самих теоремах заменялись на специальные обозначения вида `formula_№`, где № – порядковый номер формулы в данном файле.

К каждому преобразованному таким образом математическому утверждению применялся синтаксический анализатор Stanza, который создавал таблицу для каждого слова со следующими полями:

№	Слово	Лемма	Номер родителя	Тип синтаксической связи	Часть речи
---	-------	-------	----------------	--------------------------	------------

Для преобразования математических формул в абстрактное синтаксическое дерево, используется РБНФ-грамматика (расширенная форма Бэкуса — Наура) и библиотека для Python 3 TatSu, которая позволяет по файлу с правилами грамматики построить дерево.

Для Алгоритмов 1 и Алгоритмов 3 по таблице с синтаксической и морфологической информацией строится представление теоремы в виде списка вложенных списков, в котором обозначения `formula_№` заменены на соответствующие разборы этих формул.

3.2 Описание модуля перевода текста, написанного на естественном языке, на язык формул логики предикатов

Входными данными для данного модуля являются предложения, записанные на естественном языке. Математические формулы в данном предложении заменены на обозначения типа «`formula_№`», где № – номер соответствующего обозначения или формулы в файле со списком обозначений и формул. Выходными данными для данного модуля является исходное предложение, записанное при помощи логики предикатов.

Входные данные подаются синтаксическому анализатору Stanza. Результат работы анализатора представляет собой таблицу (массив), содержащий подробную морфологическую и синтаксическую информацию, соответствующую обозначениям Национального Корпуса Русского Языка (СинTagРус).

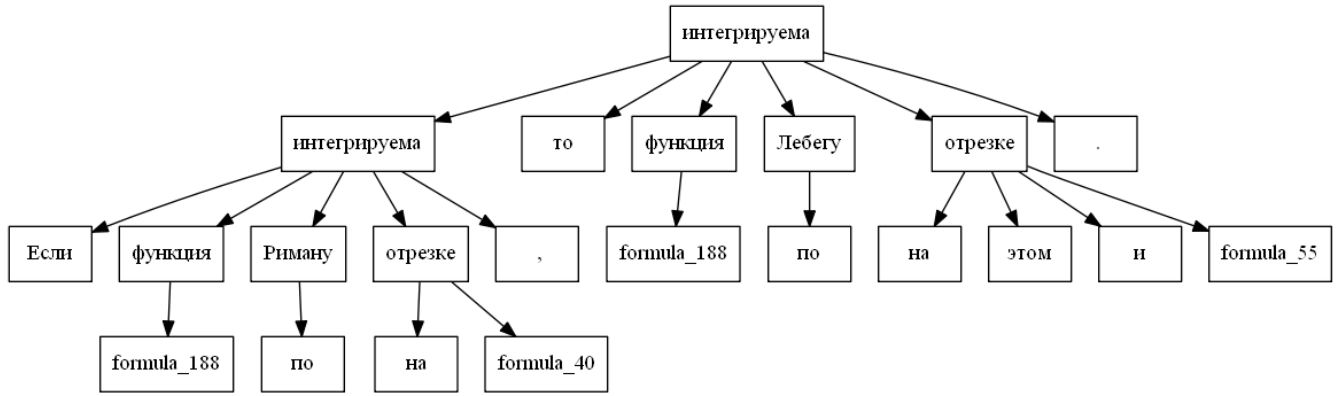


Рис. 1: Дерево синтаксического разбора теоремы

Каждый токен входного предложения представляет собой отдельный массив в данной таблице. В данном массиве содержится порядковый номер токена, его словоформа, лемма, номер родителя, тип связи между родителем и данным токеном, часть речи данного токена.

Для дальнейшей работы в полученную таблицу необходимо внести корректировки.

На первом этапе несколько отдельных токенов объединяются в один и заменяются либо на соответствующее название на английском языке, либо на стандартное математическое обозначение. Несколько подряд идущих токенов в таблице токенов. Например, токены, образующие конструкцию вида «интегрируема по Риману», будут заменены одним токеном R . Конструкция «знакопередающийся числовой ряд» будет заменена на конструкцию «alternating_series», а конструкция «тогда и только тогда, когда» будет заменена на токен « \Leftrightarrow ». При каждой такой замене происходит пересчет номеров родителей для дочерних токенов.

Для математических терминов написан словарь, где указаны соответствующая лемма термина и эквивалентное ему слово, на которое его можно заменить. Если произошло совпадение токена и значения в словаре, то будет произведена замена.

Дерево синтаксического разбора перестраивалось таким образом, чтобы вершины дерева с обозначениями forall, if, then, \Leftrightarrow , exists стали вершинами максимально возможных по размеру поддеревьев. Например, для теоремы: Если функция f интегрируема по Риману на отрезке $[a, b]$, то функция f интегрируема по Лебегу на этом

отрезке и $\int_{[a,b]} f \cdot d\mu = \int_a^b f(x)dx$ синтаксическое дерево изображено на рисунке 1.

А ее представление в виде списка вложенных списков на рисунке 2.

По дереву синтаксического разбора строится список вложенных списков (массив вложенных массивов), где вершиной списка является родительская вершина.

```

['if',
 [
  ['Riemann_integrable', [['function', [[['f']]]], ['segment', [[['a'], ['b']]]]],
  ['then', [
   ['Lebesgue_integrable', [['function', [[['f']]]],
    ['segment', [[['\int', ['_', ['a'], ['b']]], ['*', ['f'], ['d', ['='], ['\mu'],
    ['\int', ['_', ['a']], ['^', ['b']], ['*', ['f', ['x']], ['dx']]]]]]]]]]]
 ]
]

```

Рис. 2: Представление теоремы в виде списка вложенных списков

В данный список вложенных списков вместо обозначений «formula_№» подставляется дерево разбора соответствующей формулы.

3.3 Описание модуля преобразования математических формул

На вход данному модулю поступает математическая формула, записанная в формате системы TeX.

На предварительном этапе работы модуля при помощи регулярных выражений из нее удаляются слова, которые не несут никакой смысловой нагрузки: `displaystyle`, `textstyle`, `right`, `left`, `limits`, `nolimits`, `quad`. Некоторые обозначения заменяются на эквиваленты.

№	Обозначение	Эквивалент в программе	Значение
1	{ .. }	set	множество
2	[..]	closed_interval	отрезок
3	..	norm	норма
4	..	abs	модуль

Таблица 2: Примеры заменяемых обозначений

Для построения абстрактного синтаксического дерева формулы в данном модуле используется библиотека `TatSu`. Это библиотека генерирует код на языке Python из грамматик в вариации РБНФ (расширенная форма Бэкуса — Наура).

Описание грамматики в РБНФ представляет собой набор правил, определяющих отношения между терминальными символами (терминалами) и нетерминальными символами (нетерминалами).

Основным преимуществом парсера `TatSu` является то, что каждая операция парсинга грамматики при необходимости может быть отредактирована при помощи написания функции на языке Python 3.

3.4 Модуль функции ранжирования

Под коэффициентом ранжирования будем понимать некое число от 0 до 1. Чем это число ближе к 1, тем выше схожесть между двумя объектами.

В качестве входных данных для данного модуля поступают два дерева (формула), разобранных при помощи модуля перевода текста, написанного на естественном языке, на язык формул логики предикатов и модуля преобразования математических формул A и B . Для каждой из формул рекурсивно построим множество всех путей, начиная от корневой. Назовем эти два множества A' и B' .

Для множеств A' и B' вычисляется коэффициент Жаккара по следующей формуле:

$$K = \frac{n(A' \cap B')}{n(A' \cup B')}, \text{ где } n(C) - \text{ количество элементов в множестве } C$$

Если обе формулы одинаковы, то коэффициент K равен 1. Чем больше различий между формулами, тем значение K ближе к 0.

3.5 Описание графического интерфейса программы

Для удобства использования всех модулей программы написан графический интерфейс. Интерфейс представляет собой 4 текстовых поля и ряд кнопок:

Текстовые поля

1.1. Поле ввода используется для ввода информации.

1.2. Два поля вывода данных нужны для вывода результата работы.

1.3. Поле вывода ошибок используется для вывода ошибок, возникших в результате работы.

Кнопки

2.1. Clean - очистка всех текстовых полей кроме поля ввода.

2.2. Load_and_run. После нажатия данной кнопки произойдет обращение к файлу конфигурации, будет найдено поле Infile. К соответствующему этому полю пути будет добавлен путь корневой директории. Данные из файла, находящегося по данному пути (в качестве данных могут выступать текстовое утверждение или массив с синтаксической информацией) будут преобразованы в формулу данного утверждения. Результат разбора будет выведен в первое поле вывода данных. Входные данные для разбора будут выведены во второе поле вывода данных.

2.3. Parse - данные из поля ввода (текстовое утверждение или массив с синтаксической информацией) будут преобразованы в формулу данного утверждения. Результат

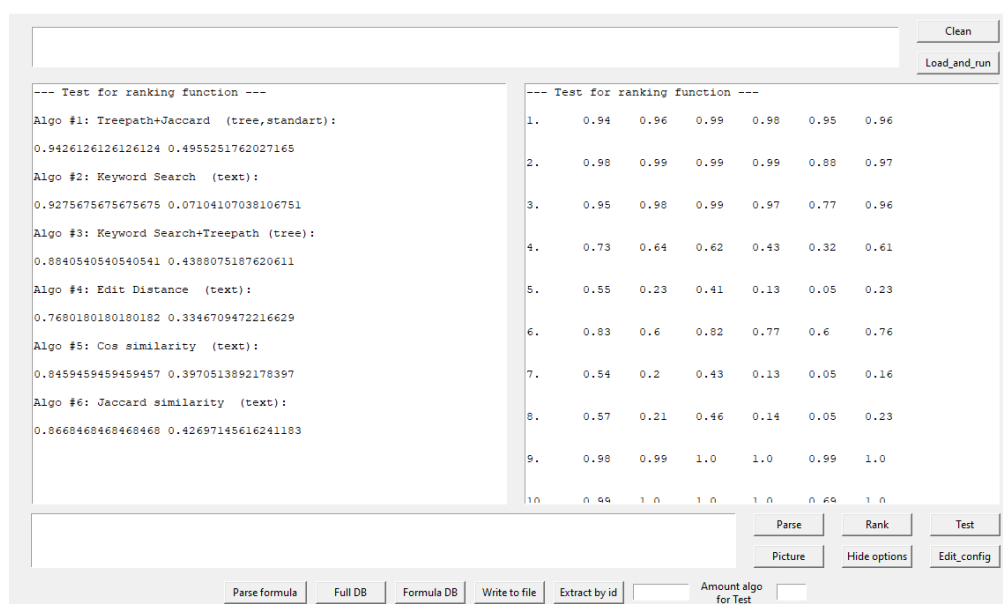


Рис. 3: Графический интерфейс программы

разбора будет выведен в первое Поле вывода данных.

2.4. Rank - запуск ранжирования. Данные из поля ввода (текстовое утверждение или массив с синтаксической информацией) будут преобразованы в соответствующую формулу данного утверждения. Полученная формула будет сравниваться с каждой формулой из базы формул. Чем выше результат сравнения (от 0 до 1), тем выше формула из базы формул будет в итоговой выдаче. Отсортированные формулы из базы формул будут выведены в первое поле вывода данных. Результаты сравнения будут выведены во второе поле вывода данных.

2.5. Test - запуск тестирующего модуля.

2.6. Picture - модуль отрисовки формул. Входные данные должны быть в формате списка вложенных списков. Данный модуль отрисовывает данные из поля ввода в отдельном окне.

2.7. Edit_config - редактирование файла конфигурации. Данные из данного файла будут выведены во второе поле вывода данных. Для сохранения изменений необходимо нажать кнопку Save_config.

2.8. Parse_formula - осуществляет преобразование формулы из текстового представления в виде дерева.

2.9. Full_DB - создает базу данных

2.10. Formula_DB - создает базу разбора формул.

Заключение

Результаты, полученные в ходе выполнения проекта, можно резюмировать следующим образом:

1. Написана и протестирована программа, способная найти само утверждение или похожее на него в базе данных с математическими теоремами.

Данная работа весьма актуальна, потому что система, способная искать похожие математические утверждения в базах данных, написанные с использованием естественного языка и формул на языке TeX, сможет найти применение в любой сфере деятельности, где используется математический язык.

2. Для тестирования работы программы были выбраны 111 математических теорем из разделов математики. При тестировании результат проверялось сможет ли реализованная программа найти не только саму себя, но и другую формулировку этой же теоремы.

Несмотря на низкий результат программу нужно улучшать для разбора большего количества теорем, пополнять внутренние словари, повышать качество их разбора. Также дополнительный интерес представляет дальнейшее совершенствование алгоритма ранжирования.

Список литературы

- [1] Hiroyuki Yamauchi. Processing of syntax and semantics of natural language by Predicate Logic. Institute of Space and Aeronautical Science, University of Tokyo. <https://www.aclweb.org/anthology/C80-1059>
- [2] Julian E. Herwitz. Natural Language to Predicate Logic https://www.cs.rochester.edu/~brown/173/exercises/samples/ParseTranslate10_2.pdf. Страница 5.
- [3] <https://stanfordnlp.github.io/stanza/>
- [4] <http://www.ruscorpora.ru/new/instruction-syntax.html>
- [5] Апресян Ю. Д., Богуславский И. М., Иомдин Б. Л. и др. Синтаксически и семантически аннотированный корпус русского языка: современное состояние и перспективы // Национальный корпус русского языка: 2003—2005. М.:Индрик, 2005, 193—214.
- [6] <https://tatsu.readthedocs.io/en/stable/intro.html>
- [7] Информационная технология — Синтаксический мета-язык — Расширенная Форма Бэкуса-Наура (Extended BNF) <https://www.cl.cam.ac.uk/~mgk25/iso-14977.pdf> Перевод Андрея Бушмана. ISO/IEC 14977 https://docs.google.com/file/d/0B7H_2Cq9tBXdd2prejdTRlJlSDA/edit
- [8] Кнут Д. Э. Все про TeX = The TeXbook / Пер. с англ. М. В. Лисиной. — Протвино: АО R^DTeX, 1993. — 592 с.
- [9] David Beazley, Guido Van Rossum. Python: Essential Reference. — New Riders Publishing, 1999.
- [10] <https://www.python.org/>
- [11] *Большакова Е.И., Воронцов К.В., Ефремова Н.Э., Клышинский Э.С., Лукашевич Н.В., Сапин А.С.* Автоматическая обработка текстов на естественном языке и анализ данных: учеб. пособие — М.: Изд-во НИУ ВШЭ, 2017. — 269 с. Страницы 25-28.
- [12] Jaccard P. Distribution de la flore alpine dans le Bassin des Dranses et dans quelques regions voisines // Bull. Soc. Vaudoise sci. Natur. 1901. V. 37. Bd. 140. S. 241—272.
- [13] В. И. Левенштейн. Двоичные коды с исправлением выпадений, вставок и замещений символов. Доклады Академий Наук СССР, 1965. 163.4:845-848.
- [14] Evgeny Pyshkin. University of Aizu, Japan. Mathematical Equation Structural Syntactical Similarity Patterns: A TreeOverlapping Algorithm and Its Evaluation <https://pdfs.semanticscholar.org/53d4/e6043e49e42cbd90fc86185a6c7af6030bbd.pdf>
- [15] Yuping Qin, Junnan Guo, Aihua Zhang. A Mathematical Formula Matching Algorithm Based on MathML <https://www.atlantispress.com/proceedings/lemcs-15/25838389>
- [16] An Approach to Similarity Searchfor Mathematical Expressions using MathML https://dml.cz/bitstream/handle/10338.dmlcz/702557/DML_002-2009-1_5.pdf